Estimation de variabilité pour le démélange non-supervisé d'images hyperspectrales

Pierre-Antoine Thouvenin [1], Nicolas Dobigeon, Jean-Yves Tourneret

Université de Toulouse, IRIT/INP-ENSEEIHT

XXV$^{\text{e}}$ colloque Gretsi, ENS Lyon

9 Septembre 2015

1. Thèse financée par la Direction Générale de l'Armement (DGA).

Introduction : principe du démélange

- Images hyperspectrales : forte résolution spectrale (10 nm), faible résolution spatiale (20 m $\times$ 20 m) ;
- Spectres observés : mélange de plusieurs signatures élémentaires (*endmembers*) ;
- Endmembers présents dans des proportions inconnues en chacun des pixels (*abondances*).

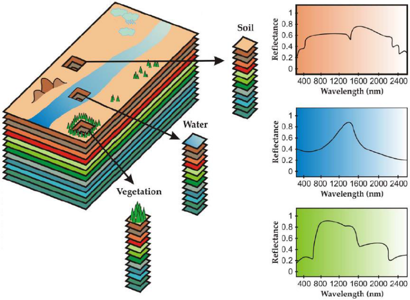

FIGURE 1: Principe du démélange.

Modèle de mélange classique

Modèle de mélange linéaire

Observations représentées par une combinaison linéaire des endmembers recherchés

$$\forall n \in [\![1, N]\!], \quad \mathbf{y}_n = \sum_{k=1}^{K} a_{kn}\mathbf{m}_k + \mathbf{b}_n \tag{1}$$

$$\mathbf{Y} = \mathbf{M}\mathbf{A} + \mathbf{B} \tag{2}$$

Contraintes

$$\mathbf{A} \succeq \mathbf{0}_{K,N}, \quad \mathbf{A}^T\mathbf{1}_K = \mathbf{1}_N, \quad \mathbf{M} \succeq \mathbf{0}_{L,K} \tag{3}$$

Démélange et variabilité spectrale

- Variation des signatures élémentaires identifiées en fonction des conditions d'acquisition : variabilité spectrale ;
- Variabilité : l'un des facteurs d'erreur majeurs lors de l'estimation des coefficients d'abondances ;
- Risque de propagation des erreurs d'estimation dans le cas de procédures non-supervisées $\Rightarrow$ nouveaux modèles nécessaires.

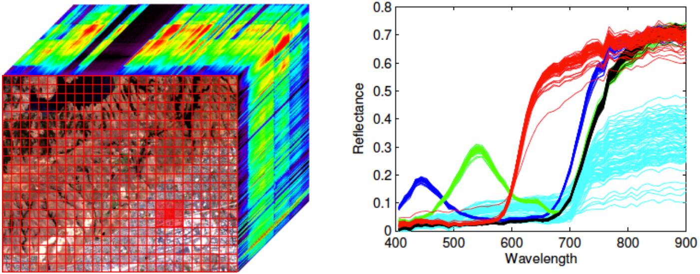

(a) Variabilité spatiale (inter-pixel) (b) Variabilité des endmembers [2]

FIGURE 2: Variabilité spectrale.

2. P. Gader, A. Zare, R. Close, J. Aitken, G. Tuell, MUUFL Gulfport Hyperspectral and LiDAR Airborne Data Set, University of Florida, Gainesville, FL, Tech. Rep. REP-2013-570, Oct. 2013.

Démélange et variabilité spectrale (suite)

Deux exemples de méthodes proposées dans la littérature pour aborder la variabilité

- Automated endmember bundles (AEB) [1, 2, 3]
  - ▷ utilisation d'une librairie de signatures spectrales pour le démélange (extraite des données ou disponible *a priori*).
- Normal compositional model (NCM) [4], Beta compositional model (BCM) [5]
  - ▷ endmembers modélisés par des vecteurs aléatoires.

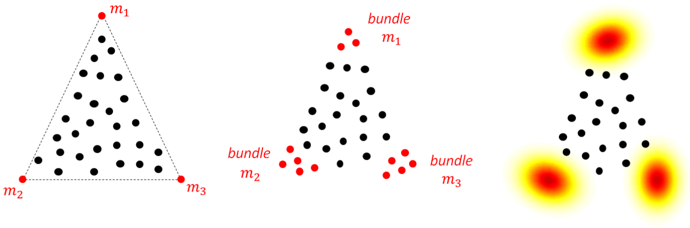

FIGURE 3: Différentes représentations de la variabilité dans le simplexe occupé par les données.

Méthode de démélange

Modèle de mélange linéaire perturbé (MMLP) [6]

Observations représentées par une combinaison linéaire d'endmembers potentiellement perturbés

$$\forall n \in [\![1, N]\!], \quad \mathbf{y}_n = \sum_{k=1}^{K} a_{kn} \left(\mathbf{m}_k + \mathbf{dm}_{n,k} \right) + \mathbf{b}_n \tag{4}$$

$$\mathbf{Y} = \mathbf{M}\mathbf{A} + \underbrace{\left[\; \mathbf{dM}_1 \mathbf{a}_1 \; \middle| \; \ldots \; \middle| \; \mathbf{dM}_N \mathbf{a}_N \; \right]}_{\boldsymbol{\Delta}} + \mathbf{B} \tag{5}$$

$\Rightarrow$ Modèle de mélange facilement adaptable en présence de variabilité spatiale et temporelle : problème abordable pour des images suffisamment petites en nombre restreint.

Contraintes

$$\begin{gathered} \mathbf{A} \succeq \mathbf{0}_{K,N}, \quad \mathbf{A}^T \mathbf{1}_K = \mathbf{1}_N, \quad \mathbf{M} \succeq \mathbf{0}_{L,K} \\ \mathbf{M} + \mathbf{dM}_n \succeq \mathbf{0}_{L,K}, \quad \|\mathbf{dM}_n\|_{\mathrm{F}}^2 \leq \sigma^2 \quad \forall n = 1, \ldots, N \end{gathered} \tag{6}$$

Méthode de démélange

Formulation du problème

$$(\mathbf{M}^*, \mathbf{dM}^*, \mathbf{A}^*) \in \underset{\mathbf{M},\mathbf{dM},\mathbf{A}}{\arg\min} \Big\{ \mathcal{J}(\mathbf{M}, \mathbf{dM}, \mathbf{A}) \text{ s.c. } (3) \Big\} \quad (7)$$

$$\mathcal{J}(\mathbf{M}, \mathbf{dM}, \mathbf{A}) = \underbrace{\frac{1}{2}\|\mathbf{Y} - \mathbf{MA} - \boldsymbol{\Delta}\|_{\mathrm{F}}^2}_{\text{attache aux données}} + \underbrace{\alpha\boldsymbol{\Phi}(\mathbf{A}) + \beta\boldsymbol{\Psi}(\mathbf{M})}_{\text{pénalités}} \quad (8)$$

Choix des pénalités :

- Φ : favoriser des abondances spatialement lisses
- Ψ : contraindre le volume occupé par le $(K-1)$-simplexe formé par les endmembers.

À partir d'une solution initiale, résolution du problème à l'aide d'un algorithme de minimisation alternée : PALM (Proximal alternating linearized minimization[3]).

3. J. Bolte, S. Sabach, and M. Teboulle, "Proximal alternating linearized minimization for non-convex and nonsmooth problems," Mathematical Programming, vol. 1-2, no. 146, pp. 459–494, July 2013.

Pénalités choisies

Pénalité sur les abondances

Pénalité visant à favoriser une variation spatiale lisse [a]

$$\Phi(\mathbf{A}) = \frac{1}{2}\|\mathbf{AH}\|_{\mathrm{F}}^{2} \tag{9}$$

où $\mathbf{H} \in \mathbb{R}^{N \times 4N}$ permet de calculer les différences entre les abondances d'un pixel donné et celles de ses 4 plus proches voisins.

a. J. Chen, C. Richard, and P. Honeine, "Nonlinear estimation of material abundance in hyperspectral images with "ℓ_1-norm spatial regularization," IEEE Trans. Geosci. Remote Sens., vol. 52, no. 5, pp. 2654–2665, May 2014.

Pénalité sur les endmembers

Pénalité permettant d'approcher le volume du $(K-1)$-simplexe [a] :

$$\Psi(\mathbf{M}) = \frac{1}{2}\sum_{i \neq j}\|\mathbf{m}_i - \mathbf{m}_j\|_2^2. \tag{10}$$

a. M. Berman, H. Kiiveri, R. Lagerstrom, A. Ernst, R. Dunne, and J. F. Huntington, "ICE : A statistical approach to identifying endmembers in hyperspectral images," IEEE Trans. Geosci. Remote Sens., vol. 42, no. 10, pp. 2085–2095, Oct. 2004.

Algorithme de démélange (PALM)

Algorithme 1 : Algorithme de démélange (MMLP).

Données : $\mathbf{Y}, \mathbf{A}^{(0)}, \mathbf{M}^{(0)}, \mathbf{dM}^{(0)}, \gamma_1 > 1, \gamma_2 > 1, \gamma_3 > 1$

Début

$k \leftarrow 0$;

tant que *critère d'arrêt non satisfait,*

`// Mise à jour des abondances`

pour $n = 1$ **à** N **faire**

(a) $\mathbf{a}_n^{(k+1)} \leftarrow \text{Update}\left(\mathbf{a}_n^{(k)}\right)$;

`// Mise à jour des endmembers`

(b) $\mathbf{M}^{(k+1)} \leftarrow \text{Update}\left(\mathbf{M}^{(k)}\right)$;

`// Mise à jour de la variabilité`

pour $n = 1$ **à** N **faire**

(c) $\mathbf{dM}_n^{(k+1)} \leftarrow \text{Update}\left(\mathbf{dM}_n^{(k)}\right)$;

$k \leftarrow k + 1$;

$\mathbf{A} \leftarrow \mathbf{A}^{(k)}, \mathbf{M} \leftarrow \mathbf{M}^{(k)}, \mathbf{dM} \leftarrow \mathbf{dM}^{(k)}$;

Résultats : $\mathbf{A}, \mathbf{M}, \mathbf{dM}$

Détail des étapes de mise à jour

$$\mathbf{a}_n^{(k+1)} = \mathcal{P}_{\mathcal{S}_K}\left(\mathbf{a}_n^{(k)} - \frac{1}{\lambda_n^{(k)}}\nabla_{\mathbf{a}_n}\mathcal{J}\right) \tag{11}$$

$$\lambda_n^{(k)} = \gamma_1 L_{1,n}^{(k)} \tag{12}$$

$$\mathbf{M}^{(k+1)} = \left(\mathcal{P}_{1,+}\circ\cdots\circ\mathcal{P}_{N,+}\circ\mathcal{P}_{+}\right)\left(\mathbf{M}^{(k)} - \frac{1}{\mu^{(k)}}\nabla_{\mathbf{M}}\mathcal{J}\right) \tag{13}$$

$$\mu^{(k)} = \gamma_2 L_2^{(k)} \tag{14}$$

$$\mathbf{dM}_n^{(k+1)} = \left(\mathcal{P}_{\sigma^2}\circ\mathcal{P}_{+}\right)\left(\mathbf{dM}_n^{(k)} - \frac{1}{\nu_n^{(k)}}\nabla_{\mathbf{dM}_n}\mathcal{J}\right) \tag{15}$$

$$\nu_n^{(k)} = \gamma_3 L_{2,n}^{(k)} \tag{16}$$

Table 1: Notations.

$L_{1,n}^{(k)}, L_2^{(k)}, L_{3,n}^{(k)}$	constantes de Lipschitz de $\nabla_{\mathbf{a}_n}\mathcal{J}, \nabla_{\mathbf{M}}\mathcal{J}, \nabla_{\mathbf{dM}_n}\mathcal{J}$
$\mathcal{S}_K$	simplexe unité
$\mathcal{P}_{\mathcal{S}_K}$	projecteur sur $\mathcal{S}_K$
$\mathcal{P}_{n,+}$	projecteur sur $\{\mathbf{X} \mid \mathbf{X} + \mathbf{dM}_n \succeq \mathbf{0}_{L,K}\}$
$\mathcal{P}_{+}$	projecteur sur $\{\mathbf{X} \mid \mathbf{X} \succeq \mathbf{0}_{L,K}\}$
$\mathcal{P}_{\sigma^2}$	projecteur sur $\{\mathbf{X} \mid \lVert\mathbf{X}\rVert_F^2 \leq \sigma^2\}$
γ_i	constantes > 1

Résultats : détails sur les données synthétiques

- Absence de pixels purs dans le mélange synthétique ;
- Énergie moyenne de la variabilité introduite : $5 \times 10^{-4}\%$ de l'énergie moyenne des endmembers ;
- Constantes utilisées : $\varepsilon = 2 \times 10^{-3}$, $\gamma_i = 1.1$, $\alpha = 2.4$, $\beta = 3.2 \times 10^{-3}$, $\sigma^2 = 0.12$.

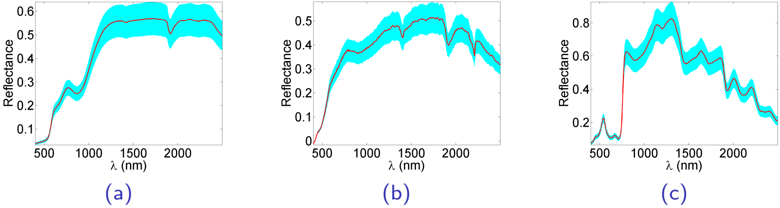

FIGURE 4: Spectres purs des données synthétiques et variabilité générée (spectres purs en rouge, variabilité en cyan).

Résultat sur données synthétiques

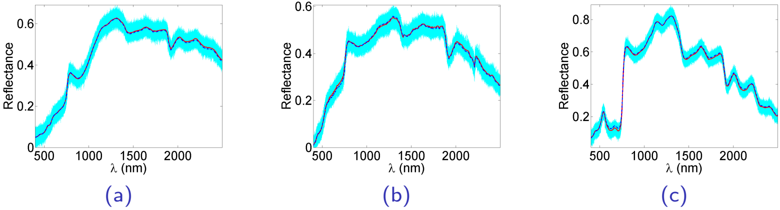

FIGURE 5: Spectres purs et variabilité estimés (spectres purs en rouge, VCA en pointillés bleus, variabilité en cyan).

TABLE 2: Résultats de simulation sur données synthétiques.

		VCA/FCLS	AEB	Méthode proposée
aSAM(**M**)	($^\circ$)	5.0639	5.1104	**4.5442**
GMSE(**A**)	($\times 10^{-2}$)	2.07	2.11	**1.52**
GMSE(**dM**)	($\times 10^{-4}$)	/	/	**5.43**
RE	($\times 10^{-4}$)	2.66	2.66	**0.52**
aSAM(**Y**)	($^\circ$)	2.0580	2.0605	**0.5114**
time	(s)	**1**	33	1678

Résultat sur données synthétiques : influence de σ^2

Deux risques lors du choix de σ^2

- σ^2 trop important : capture du bruit, risque d'introduire du bruit dans le démélange ;
- σ^2 trop faible : perte d'information (variabilité) ;
- valeur empiriquement optimale (inconnue en pratique) : $\sigma^2_{opt} = \frac{1}{N}\sum_{n=1}^{N} \|\mathbf{dM}_n^{\text{th}}\|_{\text{F}}^2$.

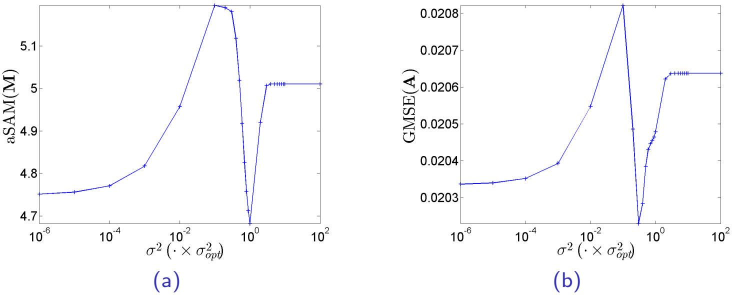

FIGURE 6: Influence du choix de σ^2 sur les résultats (aSAM($\mathbf{M}$), GMSE($\mathbf{A}$)).

Constantes utilisées : 500 itérations, $\alpha = \beta = 0$, $\gamma_i = 1.1$.

Résultat sur données réelles

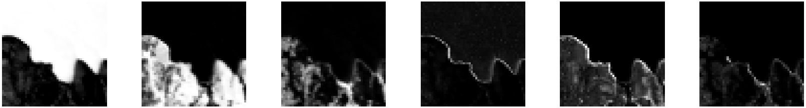

(a) Eau (b) Sol (c) Vég. (d) Var. eau (e) Var. sol (f) Var. vég.

FIGURE 7: Abondances et répartition de la variabilité [noir = 0, blanc = 1 pour les abondances, et $\max_{k,n}(\|\mathbf{dm}_{k,n}\|_2/\sqrt{L}) = 0.08$ pour la variabilité].

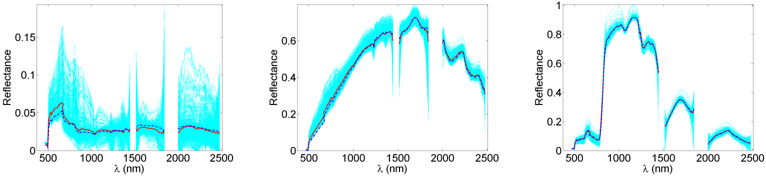

(a) Eau (b) Sol (c) Végétation

FIGURE 8: Spectres purs estimés (méthode proposée en rouge, VCA en pointillés bleus, variabilité en cyan).

Constantes utilisées : $\varepsilon = 10^{-3}$, $\alpha = 0$, $\beta = 2.2 \times 10^{-4}$, $\sigma^2 = 28.4$, $\gamma_i = 1.1$.

Conclusion et perspectives

Conclusion

- Proposition d'un modèle explicite de variabilité dans le cas de mélanges linéaires, ainsi qu'une méthode d'estimation non-supervisée ;
- Modèle suffisamment générique pour être adapté à la problématique d'images multi-temporelles.

Perspective

- Exploitation d'une série d'images hyperspectrales :
  - ▷ développement d'algorithmes en ligne pour l'exploitation des données ;
  - ▷ prise en compte de la variabilité temporelle des endmembers.

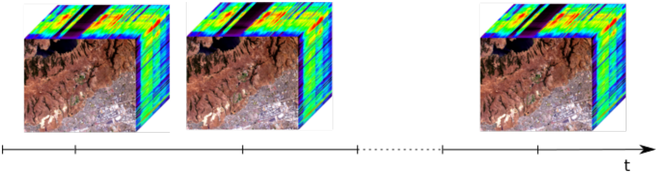

FIGURE 9: Série temporelle d'images hyperspectrales.

Merci de votre attention !

Perspective : quelques illustrations

(a) 10/04/2014 (b) 02/06/2014 (c) 19/09/2014 (d) 17/11/2014 (e) 29/04/2015

FIGURE 10: Série temporelle utilisée dans les travaux en cours.

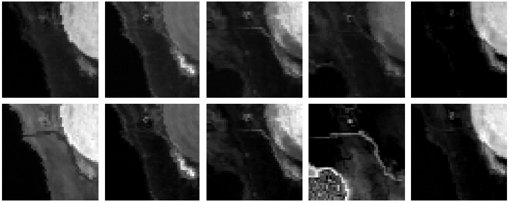

FIGURE 11: Cartes d'abondance de la végétation (PLMM ligne du haut, VCA/FCLS ligne du bas).

B. Somers, M. Zortea, A. Plaza, and G. Asner, "Automated extraction of image-based endmember bundles for improved spectral unmixing," *IEEE J. Sel. Topics Appl. Earth Observ. in Remote Sens.*, vol. 5, no. 2, pp. 396–408, April 2012.

D. Roberts, M. Gardner, R. Church, S. Ustin, G. Scheer, and R. Green, "Mapping chaparral in the Santa Monica mountain using multiple endmember spectral mixture models," *Remote Sens. Environment*, vol. 65, no. 3, pp. 267–279, Sept. 1998.

M. A. Goenaga, M. C. Torres-Madronero, M. Velez-Reyez, S. J. V. Bloem, and J. D. Chinea, "Unmixing analysis of a time series of hyperion images over the Guánica dry forest in Puerto Rico," *IEEE J. Sel. Topics Appl. Earth Observ. in Remote Sens.*, vol. 6, no. 2, pp. 329–338, April 2013.

O. Eches, N. Dobigeon, C. Mailhes, and J.-Y. Tourneret, "Bayesian estimation of linear mixtures using the normal compositional model. Application to hyperspectral imagery," *IEEE Trans. Image Process.*, vol. 19, no. 6, pp. 1403–1413, June 2010.

X. Du, A. Zare, P. Gader, and D. Dranishnikov, "Spatial and spectral unmixing using the beta compositional model," *IEEE J. Sel. Topics Appl. Earth Observ. in Remote Sens.*, vol. 7, no. 6, pp. 1994–2003, June 2014.

- P.-A. Thouvenin, N. Dobigeon, and J.-Y. Tourneret, "Hyperspectral unmixing with spectral variability using a perturbed linear mixing model," Feb. 2015, submitted. [Online]. Available : http://arxiv.org/abs/1502.01260/
- J. Bolte, S. Sabach, and M. Teboulle, "Proximal alternating linearized minimization for nonconvex and nonsmooth problems," *Mathematical Programming*, vol. 1-2, no. 146, pp. 459–494, July 2013.
- J. Chen, C. Richard, and P. Honeine, "Nonlinear estimation of material abundance in hyperspectral images with ℓ_1-norm spatial regularization," *IEEE Trans. Geosci. Remote Sens.*, vol. 52, no. 5, pp. 2654–2665, May 2014.
- M. Berman, H. Kiiveri, R. Lagerstrom, A. Ernst, R. Dunne, and J. F. Huntington, "ICE : A statistical approach to identifying endmembers in hyperspectral images," *IEEE Trans. Geosci. Remote Sens.*, vol. 42, no. 10, pp. 2085–2095, Oct. 2004.